Modelos Dimensionales

Esquema Estrella · Copo de Nieve · Data Warehouse · Data Marts

Apunte de estudio — Tecnicatura Superior en Ciencia de Datos e IA · IFTS 33 UOCRA

1.	Modelos relacionales y normalización
2.	Data Warehouse y Data Marts
3.	Modelos dimensionales: ¿qué son y para qué sirven?
4.	Técnicas de modelado dimensional
5.	Esquema Estrella (Star Schema)
6.	Esquema Copo de Nieve (Snowflake Schema)
7.	¿Qué son las dimensiones anidadas?
8.	Diseño de la tabla de hechos
9.	Comparación: Estrella vs. Copo de Nieve
10.	¿Cuándo usar cada modelo?
11.	Ejemplo práctico — Esquema Estrella
12.	Ejemplo práctico — Esquema Copo de Nieve

1. Modelos relacionales y normalización

Antes de entender los modelos dimensionales es fundamental entender qué son los modelos relacionales y por qué los sistemas transaccionales los usan, ya que el modelado dimensional es, en gran medida, una respuesta a sus limitaciones para el análisis de datos.

¿Qué es un modelo relacional?

Un modelo relacional organiza los datos en tablas (relaciones) con filas y columnas. Cada tabla representa una entidad del negocio (clientes, productos, ventas) y las tablas se relacionan entre sí mediante claves primarias y foráneas. Es el modelo utilizado por los sistemas transaccionales (ERP, CRM, sistemas de facturación) porque está optimizado para operaciones de escritura y lectura de registros individuales.

Normalización

La normalización es el proceso de organizar las tablas de una base de datos relacional para eliminar redundancias y anomalías. Se aplica en formas normales sucesivas:

Forma Normal	Regla principal	Objetivo
1FN	Cada celda contiene un único valor atómico	Eliminar grupos repetidos
2FN	Todos los atributos dependen de la clave completa	Eliminar dependencias parciales
3FN	Ningún atributo depende de otro no clave	Eliminar dependencias transitivas

Paradoja clave: la normalización es excelente para sistemas transaccionales (pocas escrituras, pocas lecturas de registros individuales), pero resulta costosa para análisis (muchos JOINs entre tablas, consultas que agregan millones de filas). Por eso los modelos dimensionales *desnormalizan* deliberadamente para ganar velocidad de consulta a costa de algo de redundancia.

2. Data Warehouse y Data Marts

Data Warehouse (DW)

Un Data Warehouse es una base de datos centralizada y unificada que integra datos de todos los sistemas de la empresa (ERP, CRM, e-commerce, RRHH, etc.). No es un sistema transaccional: su propósito es exclusivamente analítico.

Características principales:

- Orientado al análisis, no a la transacción
- Integra datos de múltiples fuentes heterogéneas
- Datos históricos: conserva el pasado para analizar tendencias
- No volátil: los datos no se modifican una vez cargados
- Los datos llegan mediante procesos ETL (Extract, Transform, Load)

Data Mart

Un Data Mart es un subconjunto del Data Warehouse orientado a un área específica del negocio o a un departamento particular. Mientras el Data Warehouse contiene toda la información de la empresa, cada Data Mart responde preguntas de un área concreta.

Data Mart	Área	Preguntas típicas
Comercial	Ventas / CRM	¿Cuáles son los productos más vendidos por región?
Logístico	Supply Chain	¿Cuál es el tiempo promedio de entrega?
Marketing	Marketing	¿Qué campaña generó más conversiones?
Financiero	Finanzas / ERP	¿Cuál es el margen por línea de producto?
RRHH	Personas	¿Cuál es la tasa de rotación por área?

Relación clave: un Data Warehouse es una colección de Data Marts. Cada Data Mart modela su área mediante un esquema estrella o copo de nieve. El DW es el contenedor; el modelado dimensional es cómo se estructura el contenido.

El proceso ETL

Los datos no llegan solos al Data Warehouse. El proceso ETL los lleva desde los sistemas transaccionales hasta el DW:

Extract (Extraer)	Se extraen datos de las fuentes: ERP, CRM, archivos CSV, APIs, etc.
Transform (Transformar)	Se limpian, unifican formatos, se resuelven inconsistencias y se aplica la lógica de negocio (equivale a tu fas
Load (Cargar)	Se cargan los datos transformados al Data Warehouse o Data Mart.

3. Modelos dimensionales: ¿qué son y para qué sirven?

El modelado dimensional es una técnica de diseño de bases de datos creada específicamente para el análisis de datos. Fue propuesta por Ralph Kimball en los años 90 y es hoy el estándar de la industria para diseñar Data Warehouses y Data Marts.

A diferencia del modelo relacional normalizado (diseñado para eficiencia en escritura), el modelo dimensional prioriza la **velocidad de consulta** y la **facilidad de comprensión** para el usuario de negocio.

> **Diferencia fundamental:** un modelo relacional te pregunta "¿cómo almaceno esto sin redundancia?". Un modelo dimensional te pregunta "¿cómo respondo preguntas de negocio de forma rápida y comprensible?"

Los dos elementos centrales del modelado dimensional son:

Tabla de Hechos (Fact Table)	Tabla de Dimensión (Dimension Table)
Contiene los eventos del negocio a analizar (ventas, pagos, inscripciones, etc.). Guarda métricas numéricas: montos, cantidades, duraciones.	Contiene el contexto descriptivo de los hechos. Responde las preguntas WHO, WHAT, WHERE, WHEN, WHY. Ejemplo: ¿qué producto? ¿en qué fecha? ¿en qué sucursal?
En Power BI se llama Tabla de medidas (PBI measures).	En Power BI se llama Tabla de búsqueda o de contexto.

4. Técnicas de modelado dimensional

Las dos técnicas principales para implementar el modelado dimensional son el **Esquema Estrella** y el **Esquema Copo de Nieve**. Ambas usan la misma lógica de tabla de hechos + tablas de dimensiones, pero difieren en cómo se organizan esas dimensiones.

5. Esquema Estrella (Star Schema)

El esquema estrella es el modelo más simple y más usado en la práctica. Recibe ese nombre porque si dibujás el diagrama, la tabla de hechos queda al centro y las tablas de dimensiones la rodean formando una estrella.

Estructura

Una tabla de hechos central conectada directamente con cada tabla de dimensión. Cada dimensión es una tabla plana, desnormalizada: toda la información descriptiva está en una sola tabla, aunque eso implique redundancia.

Características

- La tabla de hechos solo se conecta a una tabla por cada dimensión (sin saltar a otras tablas).
- Las dimensiones están desnormalizadas: pueden tener datos repetidos.
- Consultas simples: un JOIN por dimensión, sin JOINs encadenados.
- Muy eficiente para herramientas de BI (Power BI, Tableau, Metabase).
- Fácil de entender para usuarios de negocio no técnicos.

Columnas típicas de una tabla de hechos

La tabla de hechos contiene tres tipos de columnas:

- **Claves foráneas (FK):** una por cada dimensión (ID_Fecha, ID_Producto, ID_Cliente, etc.)
- **Métricas numéricas aditivas:** valores que se pueden sumar (monto_venta, cantidad, descuento)
- **Métricas semi-aditivas:** valores que no siempre se suman (saldo bancario: se suma por cuenta pero no por tiempo)

6. Esquema Copo de Nieve (Snowflake Schema)

El esquema copo de nieve es una extensión del esquema estrella donde las tablas de dimensiones están normalizadas: en lugar de una sola tabla plana por dimensión, se usan múltiples tablas relacionadas en jerarquía.

El nombre viene de la forma del diagrama: si seguís las ramificaciones de las dimensiones, el resultado se parece a un copo de nieve con sus ramas que se interconectan en varios niveles.

Características

- Las dimensiones se dividen en sub-dimensiones jerárquicas (dimensiones anidadas).
- Mayor normalización: menos redundancia, más tablas.
- Requiere más JOINs para responder las mismas preguntas que un esquema estrella.
- Más difícil de entender y mantener.
- Ocupa menos espacio en disco al eliminar redundancia en dimensiones grandes.

7. ¿Qué son las dimensiones anidadas?

Una dimensión anidada (o sub-dimensión) es cuando una tabla de dimensión no está conectada directamente a la tabla de hechos, sino que se conecta a otra tabla de dimensión que a su vez se conecta a la de hechos. Es una dimensión dentro de otra dimensión, formando una jerarquía de dos o más niveles.

Ejemplo concreto

En un esquema estrella, la dimensión de producto tiene todo en una tabla:

```
dim_producto: ID_producto | nombre | subcategoria | categoria | marca | proveedor
```

En un esquema copo de nieve, esa misma información se divide en jerarquía:

```
dim_producto: ID_producto | nombre | ID_subcategoria
dim_subcategoria: ID_subcategoria | nombre_subcategoria | ID_categoria
dim_categoria: ID_categoria | nombre_categoria | ID_marca
dim_marca: ID_marca | nombre_marca | ID_proveedor
dim_proveedor: ID_proveedor | nombre_proveedor | pais
```

Para llegar desde la tabla de hechos hasta el nombre del proveedor en el esquema copo de nieve, hay que hacer 4 JOINs encadenados. En el esquema estrella, un solo JOIN a dim_producto lo resuelve. Esa es la diferencia práctica más importante.

8. Diseño de la tabla de hechos

La tabla de hechos se diseña igual en el esquema estrella y en el copo de nieve. Lo que cambia entre ambos modelos es exclusivamente cómo se organizan las dimensiones.

Pasos para diseñar la tabla de hechos

1. **Definir el proceso de negocio:** ¿Qué evento querés analizar? Ventas, pagos, ingresos de alumnos, asistencias, etc.
2. **Definir la granularidad:** ¿Cuál es el nivel de detalle de cada fila? Una fila = una venta / un pago / un alumno inscripto. Esta decisión es la más importante y la que más impacta en el tamaño y utilidad del modelo.
3. **Identificar las dimensiones:** ¿Qué contexto rodea al hecho? Quién, qué, dónde, cuándo, por qué.
4. **Identificar las métricas:** ¿Qué números querés analizar? Monto, cantidad, duración, porcentaje.
5. **Agregar las claves foráneas:** Una FK por cada dimensión que rodea al hecho.

9. Comparación: Estrella vs. Copo de Nieve

Característica	Estrella	Copo de Nieve
Entendimiento del modelo	Sencillo	Mayor dificultad
Número de tablas	Menor	Mayor
Complejidad de la consulta	Baja	Alta
Desempeño de las consultas	Rápido	Más lento
Redundancia de datos	Mayor (más espacio)	Menor (más normalizado)
Mantenimiento	Más simple	Más complejo
Compatibilidad con BI	Excelente	Buena (con adaptaciones)

10. ¿Cuándo usar cada modelo?

Modelo Estrella — usar siempre que sea posible	Modelo Copo de Nieve — solo cuando sea necesario
• La velocidad de consulta es prioridad • Usuarios de negocio no técnicos acceden al modelo • Se usa con herramientas de BI (Power BI, Tableau) • Dimensiones de tamaño moderado • Se busca simplicidad de mantenimiento	• Una dimensión es tan grande que la redundancia degrada el rendir • Hay jerarquías muy profundas con muchos niveles • El equipo técnico es avanzado y puede gestionar la complejidad • El espacio en disco es una restricción crítica

Regla práctica de la industria: empezá siempre con el esquema estrella. Solo migrá a copo de nieve si una dimensión específica genera un problema real de rendimiento o almacenamiento. El 90% de los proyectos de BI nunca necesitan salir del esquema estrella.

11. Ejemplo práctico — Esquema Estrella

Contexto: sistema de ventas de una cadena de librerías con 50 sucursales. El equipo de marketing quiere analizar ventas por producto, fecha, sucursal y vendedor.

¿Por qué Estrella? Las dimensiones son de tamaño moderado, el equipo usa Power BI y necesita que los reportes respondan rápido. La simplicidad y velocidad son prioridad.

Diseño del modelo

Tabla de hechos: fact_ventas

Columna	Tipo	Descripción
ID_venta	PK	Clave primaria de la venta
ID_fecha	FK → dim_fecha	Cuándo ocurrió la venta
ID_producto	FK → dim_producto	Qué se vendió
ID_sucursal	FK → dim_sucursal	Dónde se vendió
ID_vendedor	FK → dim_vendedor	Quién vendió
ID_cliente	FK → dim_cliente	A quién se vendió
cantidad	INT	Unidades vendidas
precio_unit	DECIMAL	Precio unitario
descuento	DECIMAL	Porcentaje de descuento aplicado
monto_total	DECIMAL	cantidad × precio_unit × (1 - descuento)

Tablas de dimensiones

Dimensión	Columnas principales
dim_fecha	ID_fecha | fecha | año | mes | trimestre | dia_semana | es_feriado
dim_producto	ID_producto | nombre | categoria | subcategoria | marca | ISBN | editorial
dim_sucursal	ID_sucursal | nombre | ciudad | provincia | zona | metros_cuadrados
dim_vendedor	ID_vendedor | nombre | apellido | legajo | cargo | fecha_ingreso
dim_cliente	ID_cliente | nombre | apellido | email | ciudad | segmento

Diagrama del modelo estrella

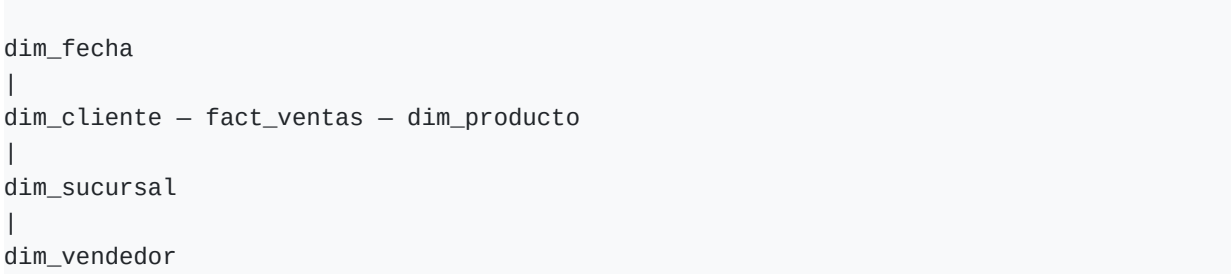

Consulta típica

```
SELECT p.categoria, s.ciudad, SUM(f.monto_total) AS total_vendido
FROM fact_ventas f
JOIN dim_producto p ON f.ID_producto = p.ID_producto
JOIN dim_sucursal s ON f.ID_sucursal = s.ID_sucursal
JOIN dim_fecha d ON f.ID_fecha = d.ID_fecha
WHERE d.año = 2025 AND d.trimestre = 1
GROUP BY p.categoria, s.ciudad
ORDER BY total_vendido DESC;
```

Resultado: un solo JOIN por dimensión. La consulta es simple, el motor de base de datos la ejecuta rápido, y Power BI puede modelarla sin configuración adicional.

12. Ejemplo práctico — Esquema Copo de Nieve

Contexto: marketplace de e-commerce con 5 millones de productos en catálogo. La dimensión de producto tiene una jerarquía profunda: producto → subcategoría → categoría → departamento → área de negocio. Si se desnormalizara en una sola tabla, cada producto repetiría el nombre de su subcategoría, categoría, departamento y área miles de veces.

¿Por qué Copo de Nieve y no Estrella? Con 5 millones de productos y 5 niveles de jerarquía, la tabla plana (estrella) sería muy grande y con altísima redundancia. Normalizar la jerarquía reduce significativamente el tamaño de almacenamiento y facilita actualizar el nombre de una categoría en un solo lugar (sin tener que actualizar millones de filas de producto).

Diseño del modelo

Tabla de hechos: fact_pedidos (igual que en estrella)

Columna	Tipo	Descripción
ID_pedido	PK	Clave primaria
ID_fecha	FK → dim_fecha	Cuándo se realizó el pedido
ID_producto	FK → dim_producto	Qué se compró
ID_cliente	FK → dim_cliente	Quién compró
ID_canal	FK → dim_canal	Cómo llegó el cliente (web, app, etc.)
cantidad	INT	Unidades compradas
monto_total	DECIMAL	Monto final del pedido

Dimensión de producto normalizada en jerarquía (dimensiones anidadas)

Tabla	Columnas	Se conecta a
dim_producto	ID_producto | nombre | SKU | precio | ID_subcategoria	fact_pedidos
dim_subcategoria	ID_subcategoria | nombre_sub | ID_categoria	dim_producto
dim_categoria	ID_categoria | nombre_cat | ID_departamento	dim_subcategoria
dim_departamento	ID_departamento | nombre_dep | ID_area	dim_categoria
dim_area	ID_area | nombre_area | responsable	dim_departamento

Diagrama del modelo copo de nieve

```
fact_pedidos
|
dim_producto
|
dim_subcategoria
|
dim_categoria
|
dim_departamento
|
```

```
dim_area

(+ dim_fecha, dim_cliente, dim_canal conectados directamente a fact_pedidos)
```

Consulta típica (más compleja que en estrella)

```
SELECT a.nombre_area, c.nombre_cat, SUM(f.monto_total) AS total
FROM fact_pedidos f
JOIN dim_producto p ON f.ID_producto = p.ID_producto
JOIN dim_subcategoria sc ON p.ID_subcategoria = sc.ID_subcategoria
JOIN dim_categoria c ON sc.ID_categoria = c.ID_categoria
JOIN dim_departamento d ON c.ID_departamento = d.ID_departamento
JOIN dim_area a ON d.ID_area = a.ID_area
GROUP BY a.nombre_area, c.nombre_cat
ORDER BY total DESC;
```

Resultado: 5 JOINs solo para llegar al área de negocio desde el producto. La consulta es más compleja y más lenta que en el esquema estrella, pero la dimensión de producto ocupa mucho menos espacio y actualizar el nombre de una categoría requiere cambiar un solo registro en dim_categoria en lugar de millones en una tabla plana. En este caso concreto, ese trade-off vale la pena.