MINERÍA DE DATOS · MANUAL DE REFERENCIA TEÓRICO-PRÁCTICO (BÁSICO A AVANZADO)

Algoritmo Apriori y Reglas de Asociación

> El algoritmo **Apriori** es un método clásico de aprendizaje no supervisado diseñado para descubrir **patrones de coaparición frecuente** en grandes bases de datos transaccionales. Su objetivo es transformar registros históricos en reglas accionables (`A → B`) aplicables a cualquier industria.

1. Fundamentos: De la Canasta de Supermercado a Cualquier Dominio

- **Diferencia con Clustering (K-Means / DBSCAN):** El clustering agrupa *observaciones o individuos similares* (filas) midiendo distancias matemáticas. Apriori descubre *elementos o atributos que aparecen juntos* (columnas) dentro de un mismo evento o contenedor.
- **Anatomía de los Datos (Transacción, Ítem e Itemset):**
  - **Transacción (Contenedor):** Es el evento agrupador único (ej. un ticket de compra `order_id`, una sesión web, un paciente o el perfil de un cliente).
  - **Ítem (Elemento):** Una variable binaria individual (ej. `Leche`, `Teclado_Mecánico`, `Fiebre`).
  - **Itemset (Conjunto):** Un grupo de ítems sin orden ni repetición: `{A, B}` es idéntico a `{B, A}`. Un conjunto con *k* elementos se denomina **k-itemset**.
- **Matriz Booleana de Presencia (0 y 1):** A Apriori clásico solo le importa si el ítem **estuvo presente (1) o ausente (0)** en la transacción, sin importar cuántas unidades se llevaron. Si la cantidad o el monto son relevantes para el negocio, se deben **discretizar** creando ítems categóricos (ej. `Compra_Mayorista`, `Ticket_Alto`).

Reproducibilidad: ¿Dónde aplicar Apriori en el mundo real?

Dominio / Industria	¿Qué es una Transacción?	¿Qué son los Ítems?	Ejemplo de Regla Descubierta
Retail / E-commerce	Un ticket o carrito (`order_id`)	Productos comprados	`{Notebook} → {Mouse, Funda}`
Streaming (Spotify/Netflix)	Historial de un usuario	Películas o artistas vistos	`{Batman, Inception} → {Interstellar}`
Salud / Diagnóstico	Consulta médica de paciente	Síntomas y antecedentes	`{Fiebre, Dolor_Muscular} → {Gripe_A}`
Banca / Clientes	Ficha de un cliente (`user_id`)	Atributos discretizados	`{Edad_25_35, Zona_Sur} → {Mora_Baja}`

2. Las 3 Métricas Fundamentales (Cálculo e Interpretación Universal)

Para evaluar qué combinaciones sirven y cuáles son puro ruido azaroso, el análisis utiliza tres medidas en cascada. Imaginemos tanto el caso de clase (**10 ventas de supermercado**) como una tienda de tecnología con **1.000 facturas**:

A. Soporte (Popularidad o Relevancia Global)

Mide en qué proporción del **total absoluto de transacciones (N)** aparece un ítem o conjunto de ítems. Sirve para garantizar que el patrón tenga volumen comercial suficiente.

$$\text{Soporte}(X) = P(X) = \frac{\text{Transacciones que contienen } X}{\text{Total de transacciones } (N)}$$

- **Regla de cálculo para conjuntos:** Nunca se suman los soportes individuales; se cuentan las filas donde **todos los elementos del conjunto aparecen simultáneamente**.
- **Ejemplo Supermercado (N = 10):** `Pan` está en 8 ventas (Soporte = 8/10 = 80%). El par `{Leche, Pan}` coincide en 5 ventas (Soporte = 5/10 = 50%).
- **Ejemplo Tech (N = 1.000):** Si 120 clientes compraron `{Auriculares, Micrófono}` en la misma factura, el soporte del par es 120 / 1.000 = 0,12 (12%).

B. Confianza (Frecuencia Condicional o Fidelidad de la Regla)

Una vez hallados los conjuntos frecuentes, se evalúan reglas direccionales (`Antecedente A → Consecuente B`). Responde a la pregunta: *"Dado que un cliente ya tiene A en su canasta, ¿qué probabilidad hay de que también lleve B?"*

$$\text{Confianza}(A \rightarrow B) = P(B \mid A) = \frac{\text{Soporte}(A \cup B)}{\text{Soporte}(A)} = \frac{\text{Transacciones con A y B juntos}}{\text{Transacciones con A}}$$

- **La Confianza NO es simétrica:** Invertir la flecha mantiene el numerador igual, pero **cambia el denominador**.
  - En el supermercado: `Leche → Pan` = 5 / 6 = **83,3%** (de 6 compras con leche, 5 llevan pan). En cambio, `Pan → Leche` = 5 / 8 = **62,5%** (de 8 compras con pan, 5 llevan leche).
  - En E-commerce: Si 100 personas compran una `Consola` y 80 de ellas llevan un `Joystick_Extra`, la confianza de `Consola → Joystick_Extra` es 80/100 = 80%.

> ⚠ **El peligro de mirar solo la Confianza (La trampa del producto estrella):** Si en un supermercado el 90% de la gente compra `Bolsa_Plástica` por defecto, cualquier regla como `Atún → Bolsa_Plástica` tendrá ~90% de confianza, aunque el atún y la bolsa no tengan ninguna relación comercial real. Para detectar esta ilusión estadística existe el **Lift**.

C. Lift (Fuerza Real de Asociación vs. Azar)

Compara la confianza de la regla contra la popularidad natural del consecuente B por sí solo. Mide cuántas veces más probable es llevar B cuando se compra A, respecto de comprarlo al azar.

$$\text{Lift}(A \rightarrow B) = \frac{\text{Confianza}(A \rightarrow B)}{\text{Soporte}(B)} = \frac{\text{Soporte}(A \cup B)}{\text{Soporte}(A) \times \text{Soporte}(B)}$$

- **Lift = 1 (Independencia):** A y B ocurren juntos por simple casualidad estadística. No hay vínculo real.
- **Lift > 1 (Asociación Positiva / Complementarios):** A impulsa la presencia de B. Ej: `Pañales → Toallitas` tiene Confianza = 70% y Soporte(Toallitas) = 20% ⇒ Lift = 0,70 / 0,20 = **3,5** (aparecen juntos 3,5 veces más de lo normal).
- **Lift < 1 (Asociación Negativa / Sustitutos):** Quien lleva A tiende a NO llevar B (ej. `Coca_Cola → Pepsi` con Lift = 0,30; o en clase `Leche → Queso` con Lift = 0,833).
- **Propiedad de Simetría:** Como el denominador es un producto, **Lift(A → B) = Lift(B → A)** siempre.

3. El Motor Matemático: Propiedad Apriori y Poda (Anti-monotonía)

En un catálogo pequeño de solo 20 productos existen **$2^{20} - 1 = 1.048.575$ combinaciones posibles** (en un supermercado con 1.000 ítems, el número supera los átomos del universo). Para evitar el colapso computacional, Apriori aplica su ley de oro:



- **Enunciado de la Propiedad Apriori:** *"Todos los subconjuntos no vacíos de un itemset frecuente también deben ser frecuentes"*. Dicho al revés (para podar): **si un conjunto NO alcanza el soporte mínimo, ningún superconjunto más grande que lo contenga podrá alcanzarlo jamás**.
- **Demostración intuitiva (Anti-monotonía):** Agregar condiciones a una búsqueda solo puede mantener o achicar los resultados: `Soporte({A, B, C}) ≤ Soporte({A, B}) ≤ Soporte({A})`. Por ende, **si `{Leche, Pan}` no alcanza el soporte mínimo, `{Leche, Pan, Queso}` jamás podrá ser frecuente con ese mismo soporte mínimo**, sin importar qué tan alto sea el soporte de `Queso` por separado.

4. Nivel Avanzado: Métricas Adicionales, Escalabilidad y Umbrales

Cuando trabajes con bases de datos reales en producción, notarás que Apriori tiene extensiones y alternativas técnicas clave que distinguen a un analista avanzado:

Métricas extra en `mlxtend`

Leverage (Apalancamiento): Mide la diferencia absoluta `Soporte(A∪B) − [Soporte(A)×Soporte(B)]`. A diferencia del Lift (que puede dar altísimo con solo 2 ventas raras), el Leverage prioriza pares con alto volumen total.
Conviction (Convicción): Mide qué tanto depende B de A evaluando la frecuencia de error (cuando aparece A pero NO B). Es sensible a la dirección de la flecha.

Apriori vs. FP-Growth

Apriori: Genera candidatos por niveles (L_1, L_2, L_3...) y escanea la base de datos repetidas veces. Excelente para explicar el proceso, pero lento con millones de filas.
FP-Growth: Comprime la base en un árbol en memoria (*FP-Tree*) y extrae conjuntos frecuentes sin generar candidatos masivos. Escala mucho mejor en Big Data.

- **Criterio profesional para elegir umbrales:** No existe una fórmula fija; depende de la dispersión del negocio. En un ejemplo de aula (10 tickets) se usa `min_support = 0.30` (30%). En un supermercado o e-commerce real con miles de artículos, casi ningún par aparece en el 30% de los carritos; allí se configura entre **`0.01` (1%) y `0.05` (5%)**. Si el soporte es muy alto, perdés nichos rentables; si es muy bajo, explota la memoria con reglas espurias.

5. Plantilla Reproducible en Python (Para cualquier Dataset)

En tus proyectos futuros te vas a encontrar con dos tipos de tablas crudas: **Formato Largo** (una fila por producto con un ID de orden repetido) o **Formato Horizontal** (una fila por compra con columnas `Item 1`, `Item 2`...). Este bloque resuelve ambos casos y ejecuta el flujo completo:

```
      # Importar librerías necesarias import pandas as pd from mlxtend.frequent_patterns
import apriori, association_rules # CASO A: Si tu dataset viene en Formato Horizontal (ej.
Groceries: Item 1, Item 2...) # Lo apilamos a formato largo para estandarizarlo en dos
columnas: order_id e item_name cols_items = [c for c in df_raw.columns if c.startswith('Item
')] df_largo = df_raw[cols_items].stack().reset_index(level=1, drop=True).reset_index()
df_largo.columns = ['order_id', 'item_name'] # CASO B: Si tu dataset YA viene en Formato
Largo (con columna de orden y de producto) # Simplemente creamos la matriz binaria de
presencia (0 y 1) usando crosstab y .gt(0) df_binario = pd.crosstab(df_largo['order_id'],
df_largo['item_name']).gt(0) # Paso 1 de Apriori: Encontrar itemsets frecuentes según el
soporte mínimo elegido frecuentes = apriori(df_binario, min_support=0.05, use_colnames=True)
# Paso 2 de Apriori: Generar reglas de asociación filtrando por confianza o lift reglas =
association_rules(frecuentes, metric="confidence", min_threshold=0.50)
print(reglas[['antecedents', 'consequents', 'support', 'confidence',
'lift']].sort_values(by='lift', ascending=False))
```

6. Cuestionario Maestro: Trampas de Examen y Preguntas Clave

Repaso definitivo de las afirmaciones capciosas que suelen evaluarse en parciales y cuestionarios teóricos:

Afirmación o Situación de Examen	Veredicto	Justificación Técnica para Responder
"Si `{Leche, Pan}` no alcanza el soporte mínimo, ¿qué pasa con `{Leche, Pan, Queso}`?"	Se poda	**No puede ser frecuente con ese mismo soporte mínimo.** Por la Propiedad Apriori, al agregar ítems el soporte solo puede mantenerse o bajar, nunca subir.
"La regla `A → B` indica que el cliente puso en el carrito primero A y luego B"	Falso	Un itemset es un conjunto sin orden temporal ni secuencia de escaneo en caja; la flecha solo indica probabilidad condicional.
"Una regla con alto Soporte, Confianza y Lift demuestra que comprar A causa la compra de B"	Falso	**Coaparición no es causalidad.** Ambos productos pueden estar impulsados por un tercer factor externo (ej. clima o día festivo).
"Una confianza del 90% siempre garantiza una asociación fuerte y útil"	Falso	Si el producto B aparece en el 95% de todas las ventas, una confianza del 90% da un `Lift < 1` (0,94), indicando que se llevan juntos menos de lo esperado.
"Alcanza con ordenar las reglas por Lift y elegir la más alta"	Falso	Dos productos raros que casualmente se compraron juntos en un único ticket tendrán un Lift gigantesco pero soporte ínfimo (regla inestable).
"Si invierto la regla de `A → B` a `B → A`, cambian tanto la Confianza como el Lift"	Falso	La **Confianza sí cambia** (cambia su denominador `Soporte(B)`), pero el **Soporte y el Lift permanecen exactamente iguales** (son simétricos).
"Si un cliente lleva 4 botellas de leche en el mismo ticket, el soporte de Leche sube más"	Falso	En Apriori binario cada transacción pesa una sola vez (`1` = presente, `0` = ausente), sin importar la cantidad de unidades.

7. Checklist para Resolver Ejercicios a Mano en 5 Pasos

1. **Contar N:** Identificar el número total de transacciones únicas (dividirás todos los soportes por este número N).
2. **Calcular Nivel 1 (L_1) y Podar:** Contar en cuántos tickets aparece cada ítem suelto, dividir por N y tachar los que sean menores a `min_support`.
3. **Armar Pares (L_2) solo con sobrevivientes:** Nunca armes parejas usando ítems tachados en el paso anterior. Contar apariciones simultáneas, dividir por N y volver a filtrar por `min_support`.
4. **Calcular Confianza (`A → B`):** Dividir el soporte del par `{A, B}` por el soporte del antecedente `A` (el que está a la izquierda de la flecha).
5. **Calcular Lift (`A → B`):** Dividir la Confianza recién obtenida por el soporte individual del consecuente `B` (el que está a la derecha de la flecha). Si da > 1, la regla es válida.